

DE_Cyt_vs_Nuc

Núria Rivera Brugués

2023-10-02

```
counts_brain_mouse<-read.delim("./GSE159919_PolyA_read_counts.txt")
counts_brain_mouse<-counts_brain_mouse[,-c(2:6)]
rownames(counts_brain_mouse)<-counts_brain_mouse[,1]
counts_brain_mouse<-counts_brain_mouse[,-1]
colnames(counts_brain_mouse)<-c("ESC_Ch1","ESC_Ch2","ESC_Ch3","ESC_N1","ESC_N2","ESC_N3","ESC_C1","ESC_C2","ESC_C3")

targets_brain_human<-read.delim("./SraRunTable.txt", header=T, sep=",")
targets_brain_human<-targets_brain_human[, c(1,13,24:26)]
info<-targets_brain_human
Sub1<-rep( c("Ch1", "N1", "C1"),each=1, len= 3)
Sub2<-rep( c("Ch2", "N2", "C2"),each=1, len= 3)
Sub3<-rep( c("Ch3", "N3", "C3"),each=1, len= 3)
info$Subgroup<-c(Sub1,Sub2,Sub3)
info$Fraction<-rep(c("Chr", "Nuc", "Cyto"), each=1, len= 9)
info$Source<-c(rep("ESC",9), rep("NPC",9), rep("Ctx",9))
info$Sample<-paste(info$Source,info$Subgroup, sep="_")
info$Group<-paste(rep(c("Chr", "Nuc", "Cyto"), each=1, len= 9), info$Source, sep="")
write.csv(info, "./info_brain.csv")

# redueixo el dataframe (nomes Cyt vs Nuc del neurones corticals primaries)
counts_primarycorticalneuron<-counts_brain_mouse[,-c(1:21)]
info<-info[-c(1:18),]
info<-info[-c(1,4,7),]
info$Subgroup<-c(1,1,2,2,3,3)
rownames(info)<-info$Sample
barcode=factor(info$Sample)
subgroup=factor(info$Subgroup)
group=factor(info$Group)
source=factor(info$Source)
fraction<-factor(info$Fraction)
c<-info[c(2,4,6),]
n<-info[c(1,3,5),]
info<-rbind(n,c)
subgroup=factor(info$Subgroup)
group=factor(info$Group)
source=factor(info$Source)
fraction<-factor(info$Fraction)

View(info)
```

```

y=DGEList(counts_primarycorticalneuron)
isexpr <- rowSums(cpm(y) > 1) >= 3
y=y[isexpr,keep.lib.size=FALSE]
y=calcNormFactors(y)
y$samples

```

```

##      group lib.size norm.factors
## Ctx_N1      1 17429224    0.9700342
## Ctx_N2      1 15973042    0.9809899
## Ctx_N3      1 23877953    0.9579471
## Ctx_C1      1 15584676    1.0241706
## Ctx_C2      1 22267101    1.0289512
## Ctx_C3      1 24501987    1.0409739

```

```

dim(y)

```

```

## [1] 13456      6

```

Exploración de los datos

Una vez descartados los genes poco expresados y con los recuentos almacenados en un objeto DGEList, podemos proceder a realizar algunos gráficos exploratorios para determinar si los datos aparentan buena calidad y/o si presentan algún problema.


Distribución de los contajes

```

boxplot(y$counts, col = y$samples$cols, las = 2, cex.axis = 0.7,
        main = "Contajes normalizados", ylim = c(0, 10000))

```

Contajes normalizados



Análisis de similitud entre las muestras


Distancia entre muestras

La función `dist` permite calcular una matriz de distancias que contiene las comparaciones dos a dos entre todas las muestras. Por defecto se utiliza una distancia euclídea.

```
log2count_norm <- cpm(y, log = TRUE)
sampleDists <- dist(t(log2count_norm))
round(sampleDists, 1)
```

```
##           Ctx_N1 Ctx_N2 Ctx_N3 Ctx_C1 Ctx_C2
## Ctx_N2    26.2
## Ctx_N3    28.7  27.4
## Ctx_C1   102.6 105.6 103.6
## Ctx_C2   107.5 108.5 105.2  36.6
## Ctx_C3    96.0  98.0  93.3  32.8  30.8
```

```
par(mfrow = c(1, 1))
fviz_dist(sampleDists)
```




Agrupamiento jerárquico

Un agrupamiento jerárquico proporciona una representación alternativa, también basada en la matriz de distancias.

```
hc <- hclust(sampleDists)
plot(hc, labels = colnames(log2count_norm), main = "Agrupamiento jerárquico de las muestras",
      cex = 0.8)
```

Agrupamiento jerárquico de las muestras

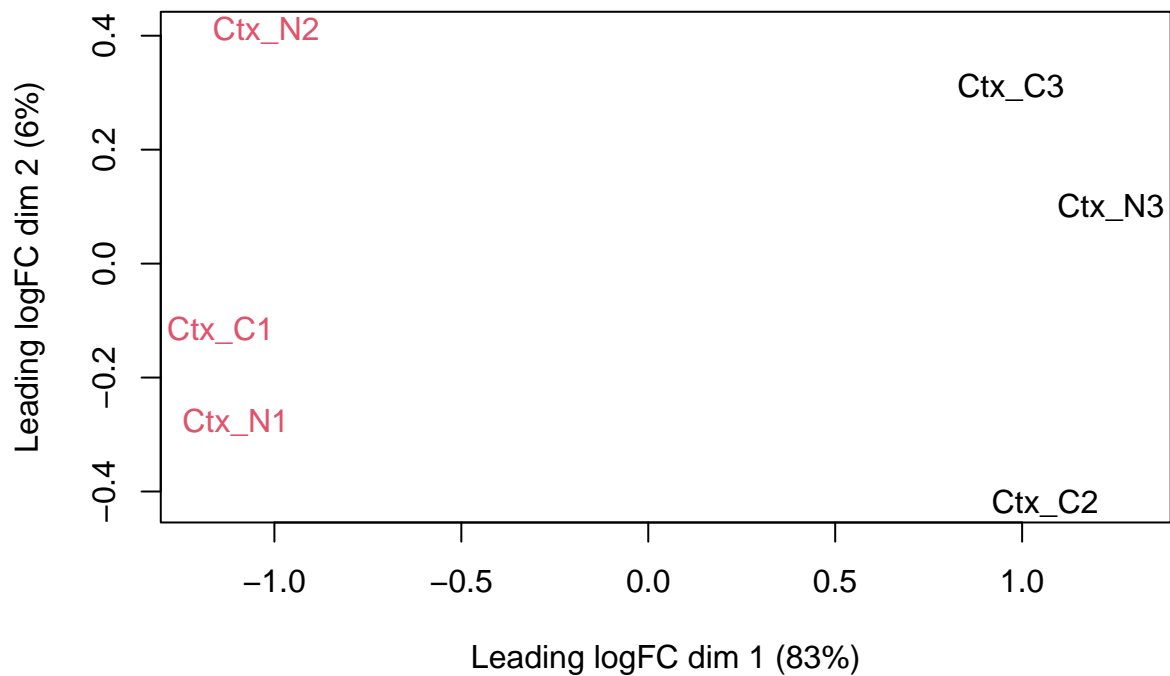


sampleDists
hclust (*, "complete")

Análisis de Escalamiento Multidimensional (MDS)

Reducción dimensional

```
plotMDS(y, col=as.numeric(fraction), labels=barcode, cex = 1 )
```





```
pdf(paste("plotMDS.pdf",sep=""))
plotMDS(y, col=as.numeric(fraction), labels=barcode, cex = 1 )
dev.off()
```



```
## pdf
## 2
```


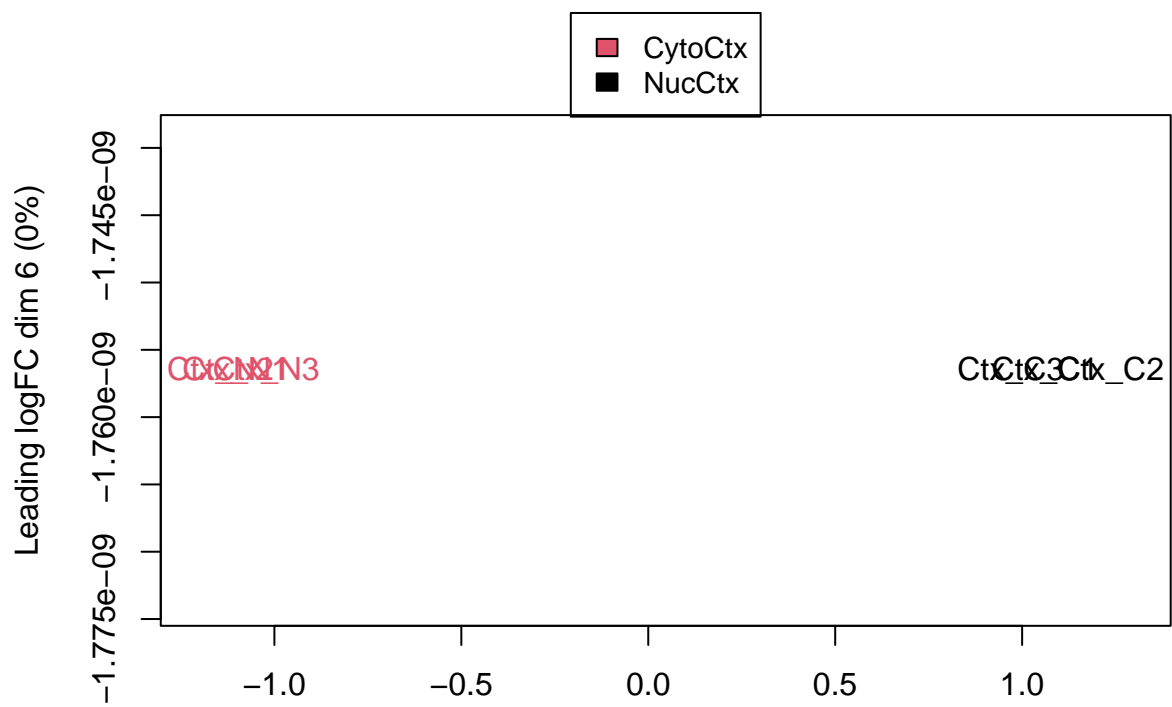
```
combi=combn(unique(c(1:6)), 2)
pdf("plotMDS_01_wo_outliers.pdf")
par(mfrow=c(2,3))
for (i in 1:ncol(combi)){
  plotMDS(y,dim.plot = combi[,i],col=as.numeric(fraction),pch=16, labels=colnames(y) )
  legend(x = "top",inset = c(0, -0.20 ), legend =levels(unique(group)), cex = 0.9 ,fill= as.numeric(uni
}
dev.off()
```



```
## pdf
## 2
```



```
for (i in 1:ncol(combi)){
  plotMDS(y,dim.plot = combi[,i],col=as.numeric(fraction),pch=16, labels=colnames(y) )
  legend(x = "top",inset = c(0, -0.20 ), legend =levels(unique(group)), cex = 0.9 ,fill= as.numeric(uni
}
```


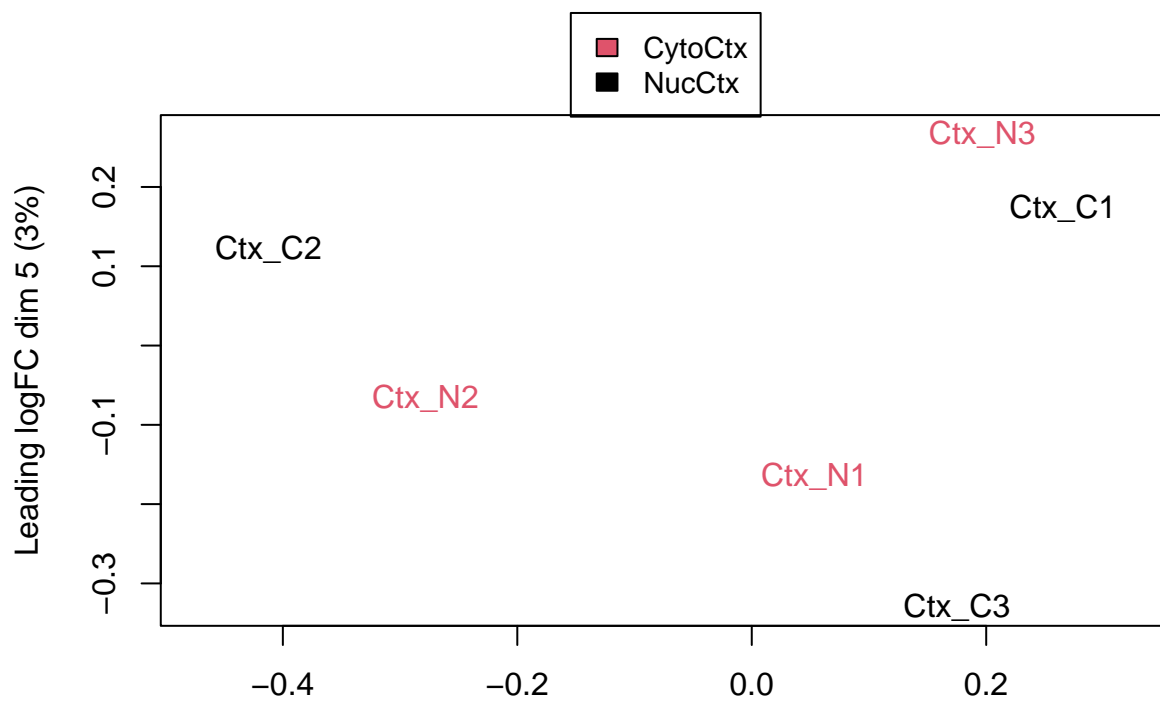

















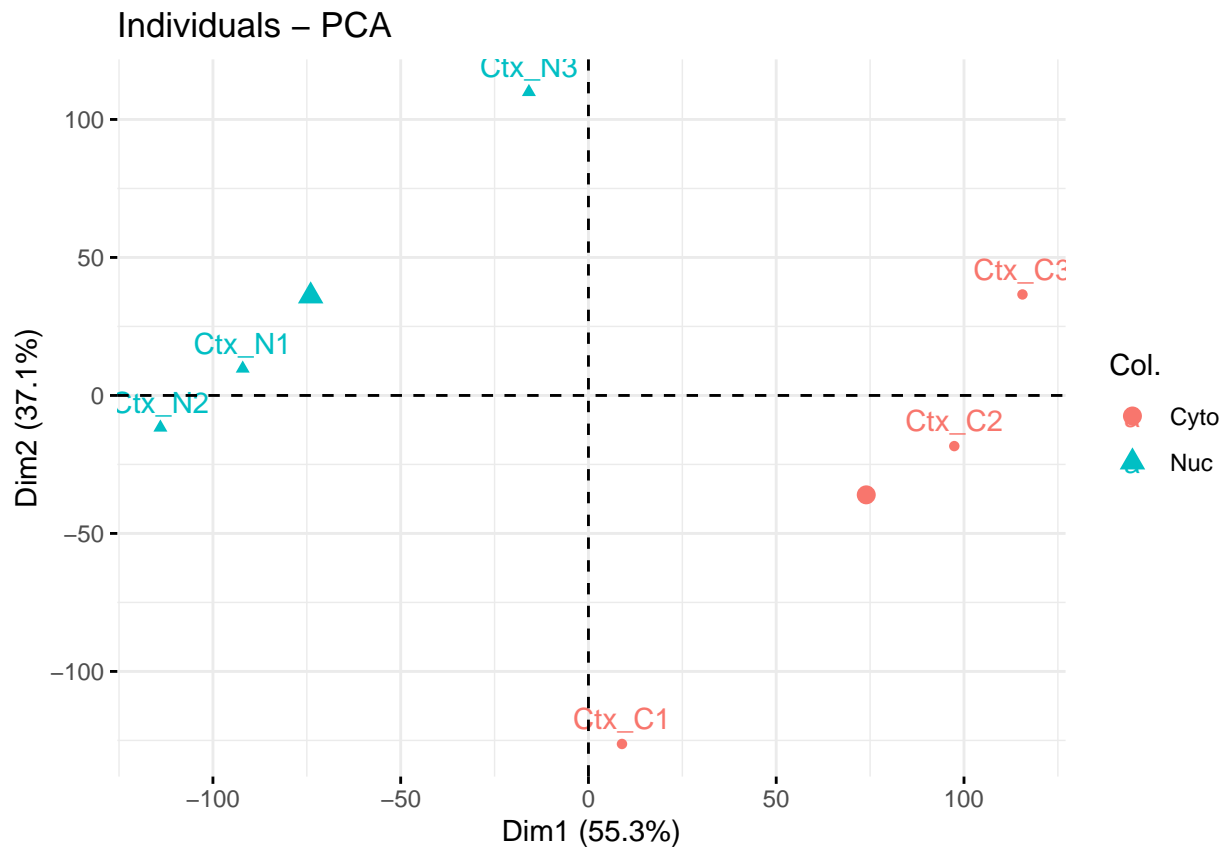


PCA

```
library(FactoMineR)

pca.raw.y <- log2(y$counts+1)

pca.y <- PCA(t(pca.raw.y), graph = F)
fviz_pca_ind(pca.y, col.ind = fraction)
```



```
pdf(paste("PCA.pdf", sep=""))
fviz_pca_ind(pca.y, col.ind = fraction)
dev.off()
```

```
## pdf
## 2
```

Análisis de expresión diferencial (DE)

El objetivo del análisis de expresión diferencial es seleccionar genes cuya expresión difiere entre grupos.


Selección de genes usando limma-Voom

La ventaja principal de esta aproximación es que permite trabajar con toda la flexibilidad de los modelos lineales para representar diseños experimentales, y, en muchos casos, aprovechar la experiencia previa del usuario en el manejo de limma.

Matriz de diseño

Utilizando la variable group podemos definir una matriz de diseño y, sobre ésta, los contrastes que nos interesan.

```
mod <- model.matrix(~0+fraction)
colnames(mod)=gsub("fraction","",colnames(mod))
pheatmap(mod,cluster_rows = FALSE,cluster_cols = FALSE)
```



```
mod
```

```
##   Cyto Nuc
## 1    0   1
## 2    0   1
## 3    0   1
## 4    1   0
## 5    1   0
## 6    1   0
## attr("assign")
## [1] 1 1
## attr("contrasts")
## attr("contrasts")$fraction
## [1] "contr.treatment"
```

Matriz de contrastes

```
contr.matrix <- makeContrasts(
  Cyto_vs_Nuc = Cyto-Nuc,
```




```
levels=colnames(mod))
contr.matrix
```

```
##      Contrasts
## Levels Cyto_vs_Nuc
##  Cyto      1
##  Nuc      -1
```

Transformación de los contajes

```
v=voom(y,mod, plot = T)
```

voom: Mean-variance trend



```
v
```

```
## An object of class "EList"
## $targets
##      group lib.size norm.factors
## Ctx_N1      1 16906943  0.9700342
## Ctx_N2      1 15669393  0.9809899
## Ctx_N3      1 22873815  0.9579471
## Ctx_C1      1 15961367  1.0241706
## Ctx_C2      1 22911761  1.0289512
## Ctx_C3      1 25505928  1.0409739
##
## $E
##      Ctx_N1  Ctx_N2  Ctx_N3  Ctx_C1  Ctx_C2  Ctx_C3
```

```
## ENSMUSG000000051951 5.209322 4.944508 5.018678 5.134058 4.248512 5.327944
## ENSMUSG000000033845 5.370636 5.335044 5.310129 5.852893 5.997191 5.801452
## ENSMUSG000000025903 3.999941 4.187469 4.086146 6.213550 5.955182 6.023772
## ENSMUSG000000033813 4.798507 4.773274 4.709582 6.833607 6.519874 6.527218
## ENSMUSG000000002459 2.627815 2.804910 2.285275 3.561908 3.479163 3.150606
## 13451 more rows ...
##
## $weights
##      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]
## [1,] 71.94695 69.36192 82.06288 66.37668 78.65919 82.12865
## [2,] 78.58302 76.00643 87.72334 88.17369 95.86449 97.46106
## [3,] 50.62680 48.50259 59.76268 91.20824 97.70441 98.89640
## [4,] 64.97664 62.49110 75.24044 98.08869 100.93620 101.66574
## [5,] 25.98371 24.56360 32.09084 36.83788 45.79962 48.67236
## 13451 more rows ...
##
## $design
##      Cyto Nuc
## 1      0      1
## 2      0      1
## 3      0      1
## 4      1      0
## 5      1      0
## 6      1      0
## attr("assign")
## [1] 1 1
## attr("contrasts")
## attr("contrasts")$fraction
## [1] "contr.treatment"
```

Selección de genes diferencialmente expresados

Como en el caso de los microarrays el objeto `v` y las matrices de diseño y contrastes se utilizaran para ajustar un modelo y, a continuación realizar las comparaciones especificadas sobre el modelo ajustado. El proceso finaliza con la regularización del estimador del error usando la función `eBayes`.

```
fit=lmFit(v,mod)
fit2 <- contrasts.fit(fit, contr.matrix)
fit2 <- eBayes(fit2)
(results<-topTable(fit2, coef = 1, adjust="BH"))
```

```
##              logFC    AveExpr      t      P.Value    adj.P.Val
## ENSMUSG000000018707 -3.458027  9.394118 -34.25716 1.490925e-13 1.055366e-09
## ENSMUSG000000014602 -3.346214  9.774906 -32.74156 2.582927e-13 1.055366e-09
## ENSMUSG000000063077 -3.239485  9.010497 -32.40273 2.930533e-13 1.055366e-09
## ENSMUSG000000026764 -3.335681  9.072041 -31.72330 3.789737e-13 1.055366e-09
## ENSMUSG000000028364 -2.381221  7.692305 -31.16199 4.705851e-13 1.055366e-09
## ENSMUSG000000034243 -3.313622  5.748709 -31.55674 4.039615e-13 1.055366e-09
## ENSMUSG000000061983  2.431092  8.596411  30.54217 6.003565e-13 1.079689e-09
## ENSMUSG000000023830 -2.663222  5.801741 -30.37332 6.420776e-13 1.079689e-09
## ENSMUSG000000084899 -2.781841  6.556294 -30.04438 7.326312e-13 1.079689e-09
## ENSMUSG000000057738 -2.359876 10.258145 -29.36990 9.645199e-13 1.079689e-09
##              B
```

```
## ENSMUSG00000018707 21.54248
## ENSMUSG00000014602 21.03362
## ENSMUSG000000063077 20.90532
## ENSMUSG000000026764 20.66371
## ENSMUSG000000028364 20.44143
## ENSMUSG000000034243 20.42183
## ENSMUSG000000061983 20.22159
## ENSMUSG000000023830 20.04695
## ENSMUSG000000084899 19.98405
## ENSMUSG000000057738 19.78011
```

```
summary(decideTests(fit2))
```

```
##           Cyto_vs_Nuc
## Down           4846
## NotSig          3480
## Up              5130
```

```
summa.fit <- decideTests(fit2, p.value = 0.01, lfc = 2)
summary(summa.fit)
```


```
##           Cyto_vs_Nuc
## Down           255
## NotSig        13150
## Up              51
```

Visualización de los resultados

Volcano Plot

```
volcanoplot(fit2, coef = 1, highlight = 10, names=rownames(fit2), main = paste( "Differentially expressed
abline(v=c(-2,2))
```

Differentially expressed genes CYT vs NUC



```
pdf(paste("volcanoplot.pdf",sep=""))
volcanoplot(fit2, coef = 1, highlight = 10,names=rownames(fit2) ,main =paste( "Differentially expressed
abline(v=c(-2,2))
dev.off()
```

```
## pdf
## 2
```

Perfiles de expresión

Con el fin de observar si existen perfiles de expresión diferenciados podemos realizar un mapa de colores con los genes más diferencialmente expresados.

Es decir, fijamos un criterio de selección de genes y retenemos aquellos componentes de la tabla de resultados que lo cumplen. Por ejemplo: Genes con un p-valor ajustado inferior a 0.001 y un ‘fold-change’ superior a 6 o inferior a -6.

mapa de colores

```
for (i in colnames(fit2$coefficients)){
  top=topTable(fit2,coef=i,sort="p", n=13456)
  genes=rownames(top[which(top$adj.P.Val<0.01 & abs(top$logFC)>2),])
  write.table(top,paste(i,"_limma_voom.txt",sep=""),quote=F)
  term1=strsplit(i,split="_vs_")[[1]][1]
  term2=strsplit(i,split="_vs_")[[1]][2]
```

```

samples=rownames(subset(info,fraction==term1 | fraction==term2))
expr=v$E[genes,samples]
rownames(expr)=do.call(rbind, strsplit(genes, ','))[,1]
if (length(genes) >1) {
  pdf(paste("pheatmap_DE_genes__01_",i,".pdf",sep=""), width = 10, height = 12)
  pheatmap(expr,scale="row",annotation_col=info[,c("Fraction","Sample")], border_color = "NA",show_row
  dev.off()
}}


write.table(v$E,"logcpm.txt",quote=F)

```

```

for (i in colnames(fit2$coefficients)){
  top=topTable(fit2,coef=i,sort="p", n=13456)
  genes=rownames(top[which(top$adj.P.Val<0.01 & abs(top$logFC)>2),])
  write.table(top,paste(i,"_limma_voom.txt",sep=""),quote=F)
  term1=strsplit(i,split="_vs_")[[1]][1]
  term2=strsplit(i,split="_vs_")[[1]][2]
  samples=rownames(subset(info,fraction==term1 | fraction==term2))
  expr=v$E[genes,samples]
  rownames(expr)=do.call(rbind, strsplit(genes, ','))[,1]
  if (length(genes) >1) {
    pheatmap(expr,scale="row",annotation_col=info[,c("Fraction","Sample")], border_color = "NA",show_row
  }}

```




```
length(which(top$adj.P.Val < 0.01 & abs(top$logFC) > 2))
```

```
## [1] 306
```

```
p_data <- top %>% filter(adj.P.Val < 0.01 & abs(logFC) > 2)
```

```
p_data %>% ggplot(aes(x=adj.P.Val,y=logFC)) +  
  geom_text(label=rownames(p_data), size=2.2,alpha=0.7, aes(col=AveExpr))
```



Top tables

```
top$Gene <- rownames(top)  
DEGs <- top %>% arrange(logFC) %>% filter(adj.P.Val < 0.01 & abs(logFC) > 2)  
head(DEGs)
```

##		logFC	AveExpr	t	P.Value	adj.P.Val
##	ENSMUSG00000084904	-4.344373	0.45675725	-12.87227	1.726451e-08	1.890246e-07
##	ENSMUSG00000062284	-3.922046	-1.60764566	-12.31525	2.864710e-08	2.703193e-07
##	ENSMUSG00000031004	-3.796871	5.29118919	-29.45542	9.311549e-13	1.079689e-09
##	ENSMUSG000000065160	-3.782379	-0.03038683	-11.90032	4.232075e-08	3.595126e-07
##	ENSMUSG00000019971	-3.716758	1.01713028	-10.22523	2.321258e-07	1.335964e-06
##	ENSMUSG00000074264	-3.479048	3.55091389	-20.55095	7.090956e-11	6.626104e-09

```
##                               B                               Gene
## ENSMUSG000000084904  9.465442 ENSMUSG000000084904
## ENSMUSG000000062284  8.710028 ENSMUSG000000062284
## ENSMUSG000000031004 19.559172 ENSMUSG000000031004
## ENSMUSG000000065160  8.636020 ENSMUSG000000065160
## ENSMUSG000000019971  7.415789 ENSMUSG000000019971
## ENSMUSG000000074264 15.303904 ENSMUSG000000074264
```

```
write.table(DEGs, file = "./DEG.txt", row.names = F, sep = "\t", quote = F)
```

```
#genes_sin_version <- sub("\\.\\d+$", "", rownames(top))
top$Gene <- rownames(top)
top <- top[,c("Gene", names(top)[1:6])]
write.table(top, file = "./Cyt_v_Nuc.txt", row.names = F, sep = "\t", quote = F)
```

Análisis de significació biológica

Nos centraremos únicamente en la lista de genes “up-regulados” y “down-regulados” es decir diferencialmente expresados con un logFC mayor que seis (más expresados en “cytosol” que en “nucleo”).

Para el análisis de enriquecimiento utilizaremos la función `enrichGO` del paquete `clusterProfiler` muy parecida a las de otros paquetes como `GOstats`.

```
head(top)
```

```
##                               Gene      logFC  AveExpr          t      P.Value
## ENSMUSG000000018707 ENSMUSG000000018707 -3.458027  9.394118 -34.25716 1.490925e-13
## ENSMUSG000000014602 ENSMUSG000000014602 -3.346214  9.774906 -32.74156 2.582927e-13
## ENSMUSG000000063077 ENSMUSG000000063077 -3.239485  9.010497 -32.40273 2.930533e-13
## ENSMUSG000000026764 ENSMUSG000000026764 -3.335681  9.072041 -31.72330 3.789737e-13
## ENSMUSG000000034243 ENSMUSG000000034243 -3.313622  5.748709 -31.55674 4.039615e-13
## ENSMUSG000000028364 ENSMUSG000000028364 -2.381221  7.692305 -31.16199 4.705851e-13
##                               adj.P.Val      B
## ENSMUSG000000018707 1.055366e-09 21.54248
## ENSMUSG000000014602 1.055366e-09 21.03362
## ENSMUSG000000063077 1.055366e-09 20.90532
## ENSMUSG000000026764 1.055366e-09 20.66371
## ENSMUSG000000034243 1.055366e-09 20.42183
## ENSMUSG000000028364 1.055366e-09 20.44143
```

```
allEntrezs <- rownames(top)
selectedEntrezsUP <- rownames(subset(top, (abs(logFC) > 2) & (adj.P.Val < 0.01)))
length(allEntrezs); length(selectedEntrezsUP)
```

```
## [1] 13456
```

```
## [1] 306
```

```
library(clusterProfiler)
library(org.Mm.eg.db)
ego <- enrichGO(gene = selectedEntrezsUP,
                universe = allEntrezs,
                keyType = "ENSEMBL",
                OrgDb = org.Mm.eg.db,
                ont = "BP",
                pAdjustMethod = "BH",
                qvalueCutoff = 0.01,
                readable = TRUE)
```

El objeto resultante almacena las categorías GO enriquecidas, los genes anotados en ellas y los valores de los estadísticos que llevan a afirmar que dichas categorías se encuentran significativamente sobre-representadas como resultado de un test de enriquecimiento.

```
head(ego)
```

```
##              ID              Description GeneRatio
## G0:0030199 G0:0030199      collagen fibril organization      9/263
## G0:0008347 G0:0008347              glial cell migration     10/263
## G0:0030198 G0:0030198      extracellular matrix organization  17/263
## G0:0043062 G0:0043062      extracellular structure organization 17/263
## G0:0045229 G0:0045229 external encapsulating structure organization 17/263
## G0:0051493 G0:0051493      regulation of cytoskeleton organization 26/263
##              BgRatio      pvalue      p.adjust      qvalue
## G0:0030199  44/12308 2.986168e-07 0.001015894 0.0008747900
## G0:0008347   62/12308 6.763865e-07 0.001150533 0.0009907282
## G0:0030198  207/12308 2.151050e-06 0.001267688 0.0010916107
## G0:0043062  207/12308 2.151050e-06 0.001267688 0.0010916107
## G0:0045229  207/12308 2.151050e-06 0.001267688 0.0010916107
## G0:0051493  436/12308 2.235782e-06 0.001267688 0.0010916107
##
## G0:0030199
## G0:0008347
## G0:0030198      Mia3/App/Lamb1/Fn1/Lamb2/Col4a2/Acan/Hspg2/
## G0:0043062      Mia3/App/Lamb1/Fn1/Lamb2/Col4a2/Acan/Hspg2/
## G0:0045229      Mia3/App/Lamb1/Fn1/Lamb2/Col4a2/Acan/Hspg2/
## G0:0051493 Dync1h1/Sptan1/Ckap5/Nes/Mycbp2/Tmsb10/Cltc/Tpr/Plxna3/Sptbn1/Agrn/Tmsb4x/Tenm1/Akap9/Map
##              Count
## G0:0030199         9
## G0:0008347        10
## G0:0030198        17
## G0:0043062        17
## G0:0045229        17
## G0:0051493        26
```

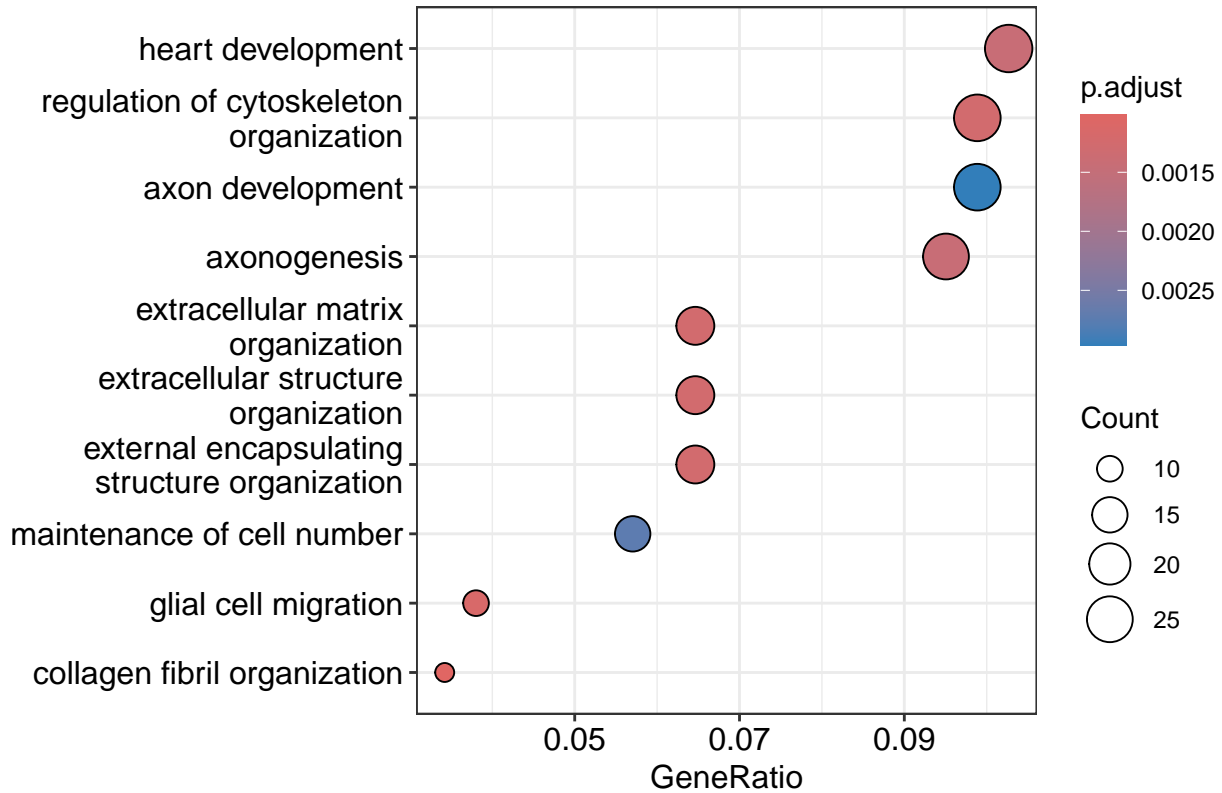
```
ego_results <- data.frame(ego)
write.csv(ego_results, "clusterProfiler_ORAresults_UpGO.csv")
```

Visualización de los resultados del análisis de enriquecimiento

Uno de los aspectos interesantes del paquete `clusterProfiler` es que permite visualizar los resultados mediante algunos gráficos creados específicamente para tal fin.

##Dotplot de los 9 términos más enriquecidos Este gráfico compara visualmente las categorías enriquecidas (de más a menos enriquecidas) visualizando simultáneamente cuan enriquecidas están y el p-valor del test de enriquecimiento.

```
dotplot(ego, showCategory=10)
```



```
pdf(paste("dotplot.pdf",sep=""))
dotplot(ego, showCategory=10)
dev.off()
```

```
## pdf
## 2
```

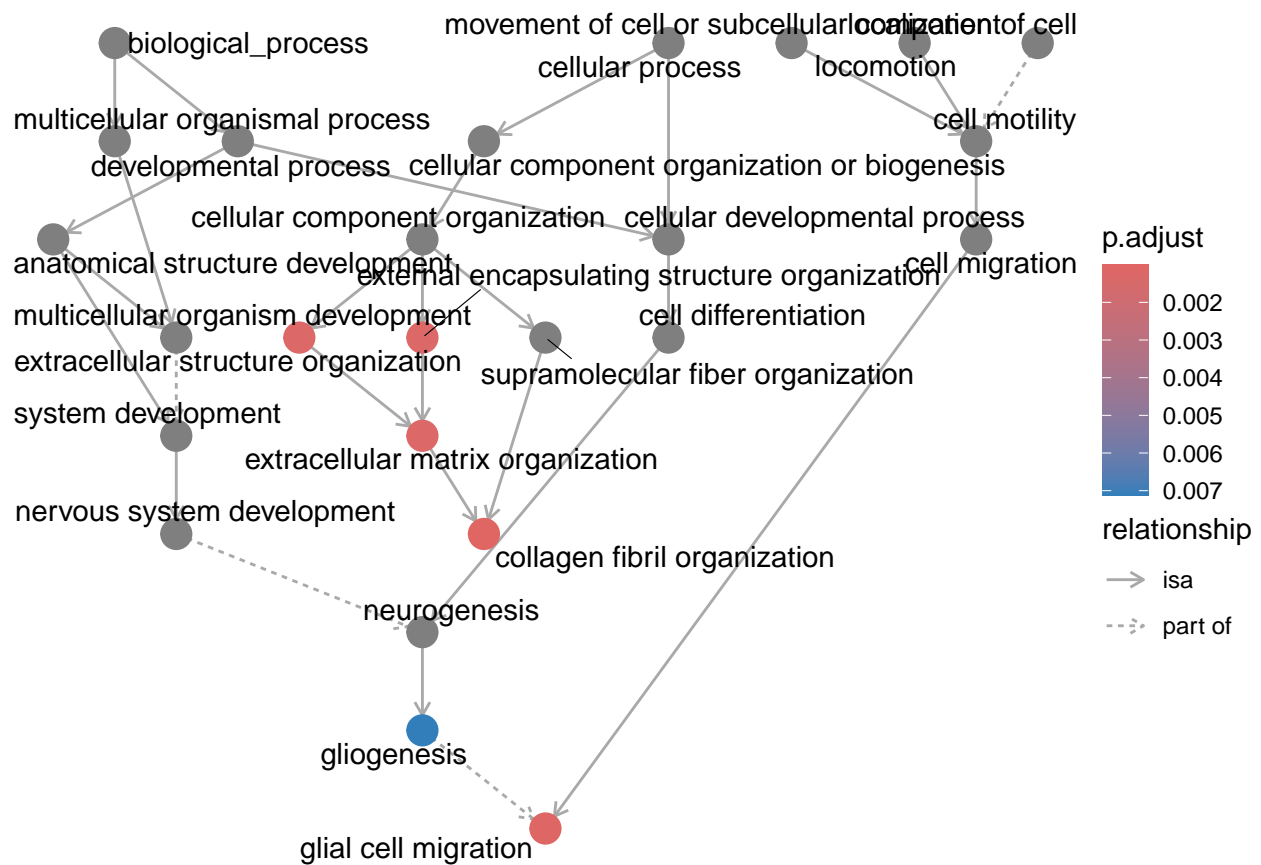
Visualización jerárquica de los términos GO

Este gráfico permite visualizar los términos seleccionados dentro del sub-grafo de la GO que los contiene. Esto nos, permite por ejemplo, hacernos una idea de si están muy dispersos, o no, en la jerarquía y de si se trata de términos muy generales o más específicos.

```
pdf(paste("GO.pdf",sep=""))
goplot(ego, showCategory=5, cex=0.5)
dev.off()
```

```
## pdf
## 2
```

```
goplot(ego, showCategory=5, cex=0.5)
```

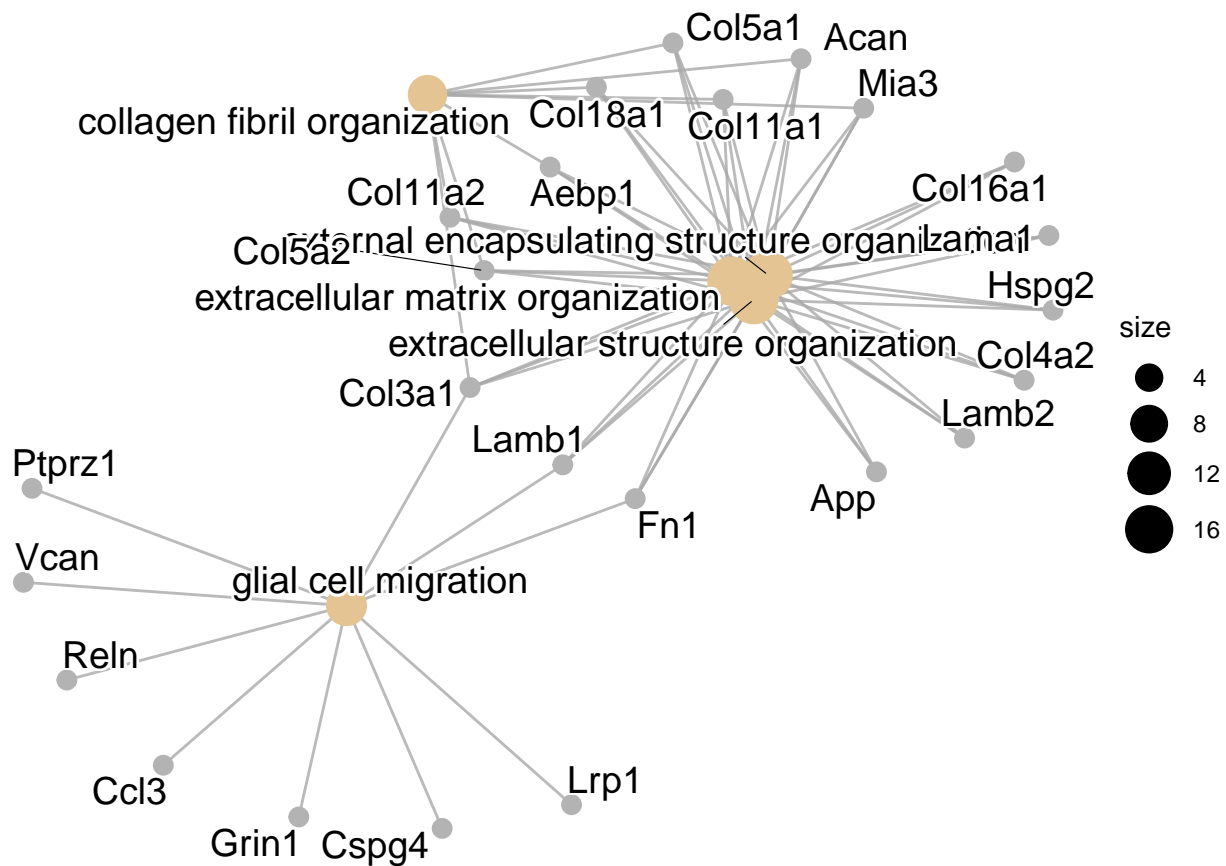


De forma parecida una red de genes nos permite visualizar la asociación entre los genes y las categorías seleccionadas en las que éstos genes están anotados.


```
## Gene network para los términos seleccionados
pdf(paste("cnetplot.pdf", sep=""))
cnetplot(ego)
dev.off()
```

```
## pdf
## 2
```

```
cnetplot(ego)
```



```
library(clusterProfiler)
library(ggplot2)
ego2 = clusterProfiler::simplify(ego, cutoff = 0.01, by = "p.adjust")
png("./cnetplot_transp.png", units = "in", width = 24, height = 16, res = 600,
    bg = "transparent")
par(bg = NA)
a <- cnetplot(ego2, showCategory = 5, cex_category = 1, cex_label_category = 2.5,
    cex_gene = 1, cex_label_gene = 1, circular = FALSE, colorEdge = TRUE)
a
invisible(dev.off())
a
```

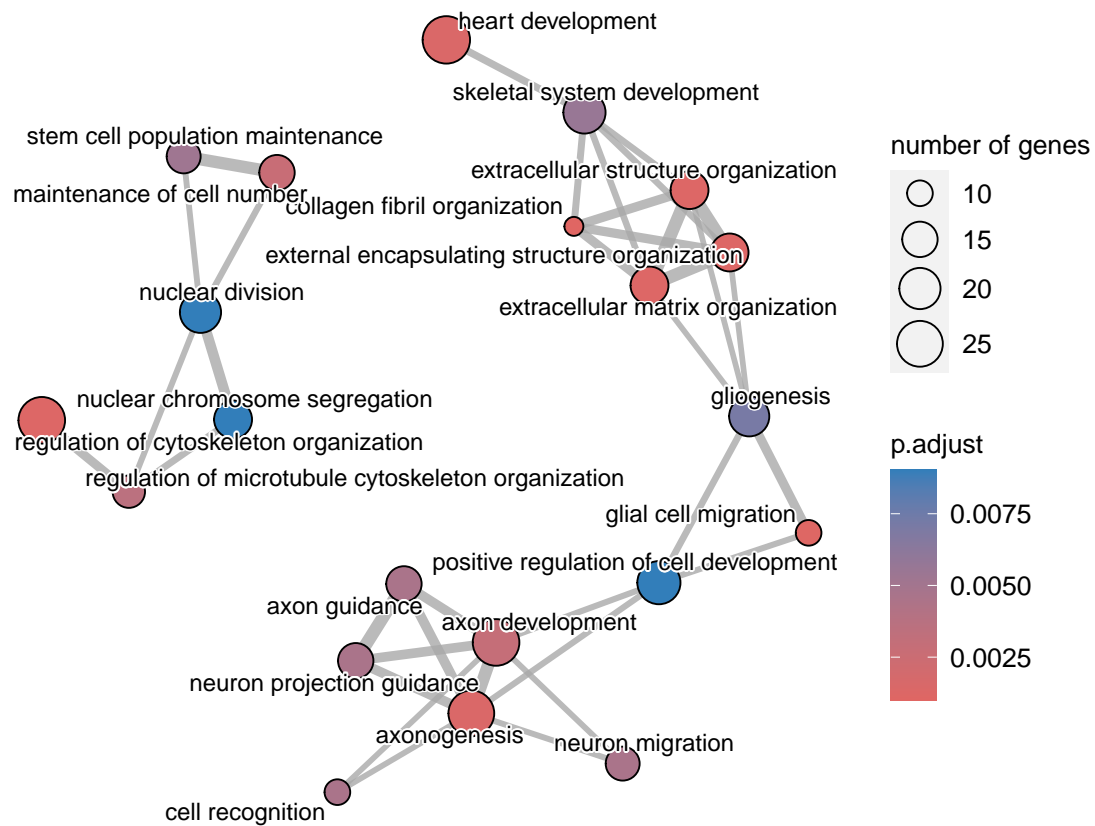


Finalmente este gráfico permite simplificar las visualizaciones y agrupa los 104 términos más significativos basándose en alguna medida de similaridad entre los mismos (por ejemplo “similaridad semántica” definida a partir de su interdistancia dentro del grafo).

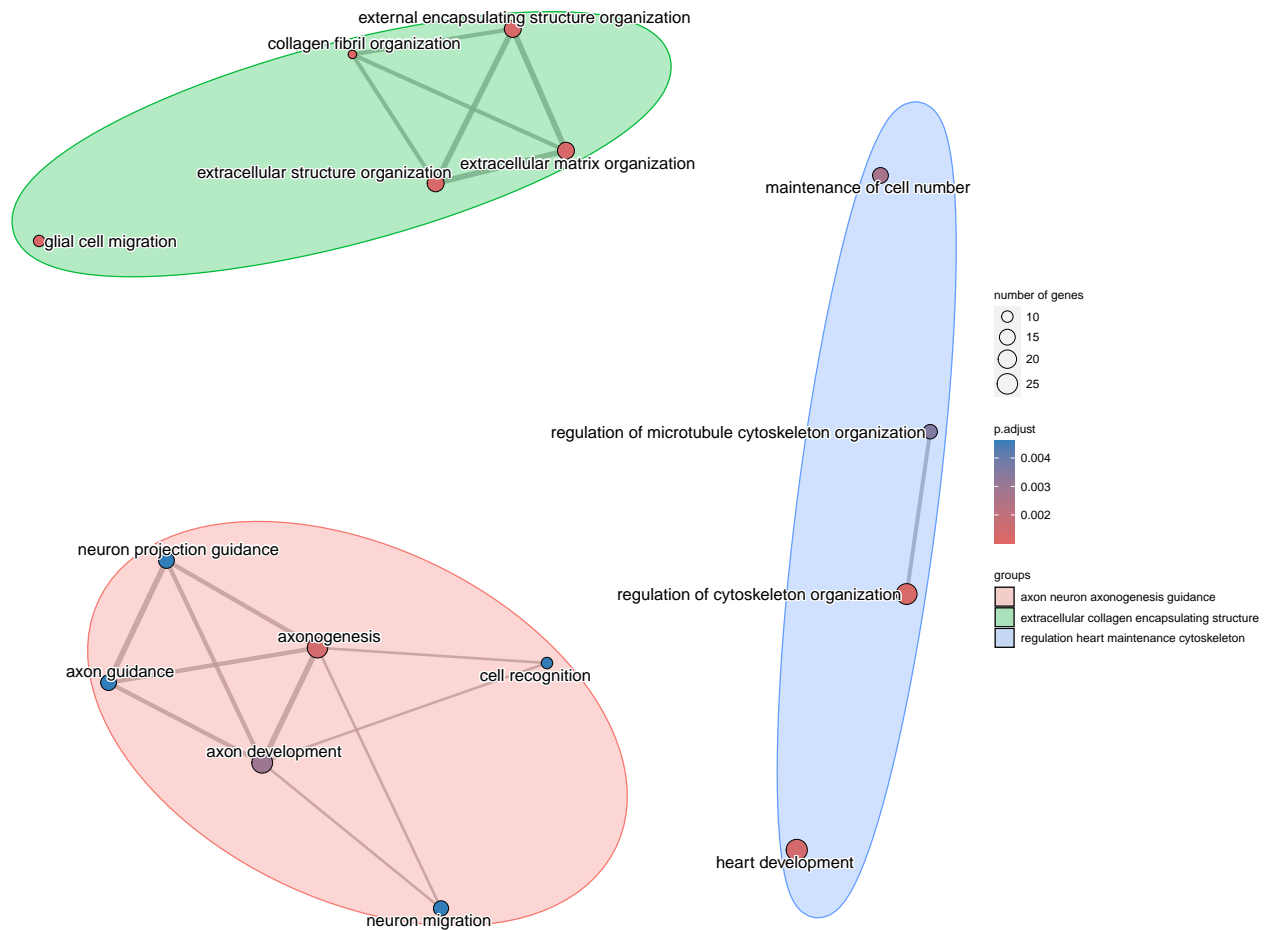
```
## Enrichment Map
library(enrichplot)
ego_sim <- pairwise_termsim(ego)
pdf(paste("emaplot.pdf", sep=""))
emapplot(ego_sim, cex_label_category=0.6)
dev.off()
```

```
## pdf
## 2
```

```
emapplot(ego_sim, cex_label_category=0.6)
```



```
term_similarity_matrix = pairwise_termsim(ego)
emapplot(ego_sim, showCategory = 15, group_category = TRUE, group_legend = TRUE)
```



```
pdf(paste("emaplot_grouped.pdf",sep=""),width = 15, height = 17)
emapplot(term_similarity_matrix, showCategory = 15, group_category = TRUE, group_legend = TRUE)
dev.off()
```

```
## pdf
## 2
```

```
library(enrichplot)
heatplot(ego)
```

